

Article Title

First Author^{1,2*}, Second Author^{2,3†} and Third Author^{1,2†}

^{1*}Department, Organization, Street, City, 100190, State, Country.

²Department, Organization, Street, City, 10587, State, Country.

³Department, Organization, Street, City, 610101, State, Country.

*Corresponding author(s). E-mail(s): iauthor@gmail.com;

Contributing authors: iauthor@gmail.com; iiiauthor@gmail.com;

[†]These authors contributed equally to this work.

Abstract

The abstract serves both as a general introduction to the topic and as a brief, non-technical summary of the main results and their implications. Authors are advised to check the author instructions for the journal they are submitting to for word limits and if structural elements like subheadings, citations, or equations are permitted.

Keywords: keyword1, Keyword2, Keyword3, Keyword4

1 Introduction

El fútbol es el deporte más seguido alrededor de todo el mundo, lo que conlleva que suscite un gran interés también desde el mundo de la estadística y la investigación científica. Los avances conseguidos en los últimos años en tecnologías de extracción de datos han permitido que se recopile gran cantidad de información sobre todo los ámbitos que envuelven el fútbol, desde métricas de rendimiento y salud individual de cada jugador, hasta las tácticas utilizadas por los entrenadores para organizar al equipo en el partido.

Todo esto ha motivado a los investigadores a realizar diferentes estudios relacionados con el fútbol. En este trabajo, nos centramos en dos temas relacionados que han suscitado especial interés, la predicción de los resultados de fútbol y el análisis de los factores que influyen en el desenlace de un partido de fútbol. Una de las razones por la que suscitan tanto interés estos temas es la aparente aleatoriedad de este deporte.

A diferencia de otros deportes como el baloncesto o el tenis el fútbol tiene tres resultados diferentes posibles: victoria de uno u otro equipo, o empate. Analizando la aleatoriedad, en [Ulmer and Fernández \(2014\)](#) calcularon la entropía de los resultados de los partidos de los datasets de los que disponían, siendo ésta de 0.72 para la temporada 2009-10 de la English Premier League. Considerando que un valor de 1 sería pura aleatoriedad, el valor de 0.72 que obtuvieron pone aun mas de manifiesto el componente aleatorio del fútbol.

Sin embargo, la distribución de los resultados no es uniforme, sino que hay resultados que a priori son más probables que otros. Además, que más del 85% de los partidos acaban ya sea en empate o con un equipo ganador por una diferencia de tan solo un gol [Berrar \(2019\)](#). Es decir, la gran mayoría de los partidos están tremendamente igualados y el resultado puede cambiar por cualquier pequeño detalle. Esto evidencia, más si cabe, la dificultad de predecir con exactitud el resultado final de un partido antes si quiera que el partido comience. La relación que existe entre los factores que determinan el resultado de un partido es extremadamente compleja y no puede ser expresada por ecuaciones [Li \(2020\)](#).

Una de las propuestas más interesantes en los últimos años fue el challenge [2027 Soccer Prediction Challenge](#) impulsado por [Berrar et al. \(2017\)](#). El challenge consistía en evaluar diferentes enfoques del problema de la predicción de partidos a partir de los resultados obtenidos en dichos estudios. Todos los participantes disponían de los mismos sets de datos y los tests eran de partidos aún por disputarse por lo que no podían disponer de los resultados. El dataset de entrenamiento¹ constó de más de 200,000 partidos para el entrenamiento (18 temporadas de 35 ligas diferentes), y cada partido constó solamente del nombre de los equipos, la fecha y el resultado, por lo que los concursantes debieron hacer uso de la creatividad y crear features a partir de los resultados históricos.

A continuación vamos a comentar algunos enfoques utilizados en la creación de características, poniendo especial interés en los participantes del *2027 Soccer Prediction Challenge*.

1.1 Feature Engineering

Una de las principales limitaciones que se han encontrado trabajos anteriores ha sido la limitación de datos disponibles públicamente en la red [Timmeraju \(2013\)](#); [Rodrigues and Pinto \(2022\)](#). Por ello, han debido de utilizar la mayoría ya sea características muy básicas o datasets con características mas avanzadas por con un volumen de datos muy pequeño. Por tanto, ha sido preciso la ingeniería de características para crear características que puedan aportar más información al modelo.

1.1.1 Strategy and tactics

La estrategia y las tácticas que usa un equipo son uno de los factores que más se ha puesto sobre la mesa en los trabajos anteriores. Sin embargo, han sido pocos los que finalmente han utilizado esta información para la predicción de partidos. De hecho, inferir o clasificar una estrategia o táctica a partir de unos datos numéricos es complejo

¹Public data in www.football-data.co.uk

y podría conformar en sí mismo un topic de investigación propio Rein (2016). Además, para la creación de características que representen información acerca la estrategia o la táctica de un equipo son necesarios datos suficientemente ricos en información que con una base de datos de estadísticas agregadas no se pueden obtener. Por ejemplo, Wang et al. (2015) utiliza una base de datos con eventos concretos y detallados (pases, faltas, fueras, robos, etc.) que ocurrieron durante los partidos para inferir las tácticas utilizadas.

Ievoli et al. (2021) utilizó grafos de pases para representar los pases entre los jugadores de un equipo. A partir de este grafo de pases extrayeron características de juego del equipo como los jugadores clave por los que pasa el juego del equipo, la conectividad promedio entre los jugadores, fluidez del juego, numero total de pases, además de otras estadísticas agregadas del equipo. Como hemos dicho anteriormente, la contraparte de estos datos tan detallados es que la base de datos estaba formada por tan solo los 96 partidos de la fase de grupos de la UEFA Champions League 2016/17².

1.1.2 Short-term historical features

En cuanto a las características creadas con datos más simples como estadísticas agregadas de un equipo en un partido, uno de los enfoques más comunes es el de usar datos acerca del estado de forma del equipo. Heuer and Rubner (2009) mostraron que una racha de derrotas tiene un efecto negativo en las probabilidades de victoria de un equipo, mientras que una racha de victorias no tiene ningun impacto positivo en la probabilidad de victoria.

Vashist et al. (2022), a partir de los datos públicos disponibles en football-data.co.uk crearon para los partidos de la liga ingles entre 2005 y 2021 dos variables booleanas por equipo que definen si ha ganado los ultimos 3 y 5 partidos, y otras dos para definir si ha perdido. Timmaraju (2013); Ulmer and Fernández (2014) también añadieron características con este approach, agregando los ultimos 7 partidos, tras probar diferentes valores durante el entrenamiento. Hubáček (2019), que fueron los ganadores del *2017 Soccer Prediction Challenge*, calcularon estas características con los ultimos 5 partidos. Además, también añadieron como parte de este conjunto de características, el número de días de descanso desde el último partido de la competición. De forma similar, Tax and Joulstra (2015), utilizando un dataset de la liga holandesa, crearon cinco variables diferentes de tipo nominal con los resultados de los ultimos 5 partidos de cada equipo. Ellos también añadieron los dias transcurridos desde el anterior partido de la competición.

Ulmer and Fernández (2014); Hubáček (2019) destacaron los problemas que tuvieron a la hora de calcular estas variables para los primeros partidos de la temporada, sin embargo, en base a los resultados, optaron por ignorar los N primeros partidos de la temporada. Frente a este problema, Berrar (2019) propuso, en cambio, usar las temporadas de una forma continua, usando los ultimos partidos de la temporada anterior para calcular las características de los primeros partido de la temporada. Sin embargo, aquí el problema que les surge es con los equipos que ascienden y descienden de categoría. Con este enfoque incorporó 4 diferentes factores con una profundidad

²Public data in <https://www.uefa.com/>

N del lag. Tras generar diferentes valores de N decidió quedarse con $N = 9$, lo que le hizo perder alrededor de 9000 partidos, un 4% del total del dataset.

Timmaraju (2013) creó también incorporó lo que llamó *Temporal Gradient k-Past Performances*, que aplica una convolución de diferenciación temporal entre partidos consecutivos, a los últimos K partidos, para así captar tendencias o cambios a lo largo del tiempo. Esto lo aplican tanto a los goles como a los corners y disparos.

Podemos apreciar como en las investigaciones pasadas se han propuesto diferentes propuestas pero todas coinciden en la importancia de encontrar un valor óptimo de partidos para agregar, valor que suele estar entre 4 y 8 partidos, y que podrían traducirse en un *lag* temporal, utilizando valores temporales reales como últimas 4 semanas o 2 meses. Sin embargo, parece que este approach no ha sido usado en los trabajos observados. Al igual, que tampoco se han usado simultáneamente diferentes variables con diferentes *lags*.

1.1.3 Long-term historical features

Otro interesante conjunto de características propuesto en la literatura, creado a partir de estadísticas agregadas de partidos son las características basadas en el rendimiento a largo de plazo del equipo en el pasado. Estas características representan mejor el prestigio de un equipo, que al final no se basa en una racha de unos pocos partidos sino en el desempeño del equipo durante una temporada entera o incluso varios años.

Rudrapal et al. (2020) quiso representar la importancia de un equipo en las últimas décadas, y para eso añadió como característica a su dataset el número de temporadas que había estado el equipo en dicha competición en los últimos 18 años.

Con un approach similar el de las características de la racha reciente de un equipo, Hubáček (2019), el ganador del *2027 Soccer Prediction Challenge*, creó un conjunto de características llamado '*Historical Strenght features*'. Para estas variables calculó las medias y la desviación estándar de los goles marcados y concedidos por un equipo, además del porcentaje de victorias y empates, y lo hizo distinguiendo si jugaba de local o visitante. La característica contenía los datos de estos factores para la presente y las dos anteriores temporadas al partido, razón por la cual tuvieron que prescindir de las primeras dos temporadas del dataset del challenge. Es importante comentar que perdieron también muchos partidos con los equipos que descendieron de categoría o que ascendieron después de más de dos años o por primera vez, ya que estos equipos no tienen datos suficientes para crear la variable. Sin embargo, lo consideraron como un sacrificio inevitable ya que no podían usar datos de partidos de una competición distinta para predecir un partido, ya que, en principio, un equipo que desciende a la 2a categoría desde la 1a categoría es uno de los equipos más fuertes de esta 2a categoría, sin embargo, los datos históricos estarían dando un sesgo negativo a ese equipo frente a otro que digamos, acaba de ascender desde una 3a categoría (considerando que disponían de datos de esa categoría), muy inferior *a priori*.

Además, analizaron la importancia de las características y este conjunto de características resultó ser el tercero en importancia a la hora de predecir el resultado, siendo tres veces más influyente que las características basadas en el estado de forma reciente.

Por otra parte, con un enfoque diferente ya que no se enfoca en el rendimiento general de un equipo, sino en el histórico particular de los enfrentamientos entre los dos

equipos que juegan un partido, [Hucaljuk and Rakipović \(2011\)](#); [Aranda-Corral \(2013\)](#) codificaron los resultados de los anteriores enfrentamientos de dos equipos. [Aranda-Corral \(2013\)](#) encontró una relación interesante de estas variables con el resultado de los partidos de la liga española. Lo hizo con tres variables, una para el número de victorias, otra para los empates y otra para las derrotas de uno de los equipos para la temporada actual y todas las anteriores disponibles. [Hucaljuk and Rakipović \(2011\)](#) incluyeron directamente el resultado de los enfrentamientos previos en su modelo para predecir los partidos de la UEFA Champions League.

Otro enfoque diferente para comparar la fortaleza de un equipo frente a otro, y que combina el estado de forma actual con el prestigio histórico de un equipo, es el de los sistemas de *rating*.

1.1.4 Rating systems

Una solución propuesta en algunos trabajos para sortear la poca información incorporada en los datasets públicos ha sido la creación de features basadas en *rating systems*. Los rating systems son características diseñadas para cuantificar la fortaleza relativa de los equipos en el fútbol capturando dinámicamente el rendimiento de los equipos a lo largo del tiempo.

Un enfoque *baseline* que se podría tomar sería añadir al dataset la posición del equipo en la clasificación. Sin embargo, tal y como explica [Constantinou and Fenton \(2013\)](#), la posición en la clasificación tiene muchos inconvenientes para ser añadida como variable: hay una gran variabilidad en la clasificación durante las primeras jornadas de la temporada y una muy baja variabilidad al final de temporada. Además que en muchas ocasiones los equipos no se encuentran en la misma jornada a la vez, además que hasta el final de temporada no se han enfrentado a los mismos equipos, por lo que la clasificación está sesgada.

Uno de los primeros, y más conocidos rating systems, es el ELO rating system, inicialmente desarrollado para clasificar jugadores de ajedrez [Elo \(1978\)](#), y aplicado al problema de fútbol por primera vez por [Hvattum and Arntzen \(2010\)](#). ELO ajusta los ratings de los equipos dinámicamente, según sus resultados en cada encuentro, considerando la diferencia entre las expectativas previas y el resultado real, el equipo ganador gana más puntos si venció a un rival más fuerte, mientras que el perdedor pierde más puntos si fue derrotado por un equipo más débil. ELO utiliza solamente información del resultado sin tener en cuenta los goles del partido. Sin embargo, concluyeron que aunque parecía ser un buen sistema para codificar información de resultados anteriores para medir la fortaleza de un equipo, su acierto no era tan bueno al ser usado para la predicción.

[Constantinou and Fenton \(2013\)](#) propusieron más tarde *pi-ratings*, un nuevo sistema de ratings que utiliza la diferencia de goles del partido para actualizar las puntuaciones de los equipos, una para su rendimiento como local y otra para visitante. Aún así, consideran el hecho de ganar en sí más importante que incrementar el resultado, por lo que van a reducir exponencialmente las grandes diferencias de goles antes de actualizar el rating. Además, añaden dos parámetros entrenables, uno para determinar la importancia de los partidos recientes frente a los antiguos, es decir, viene a ser un factor de aprendizaje; el otro para definir la importancia del sesgo de campo,

determinando la influencia de los partidos en casa en la actualización de la puntuación visitante, y viceversa. Para evaluar su sistema frente a otras versiones de ELO van a enfrentar sus predicciones a las cuotas de las casas de apuestas. El resultado de su propuesta fue muy positivo, siendo *pi-ratings* el único sistema de ratings que consiguió profit.

Más tarde, para el *2017 Soccer Prediction Challenge*, Hubáček (2019) incorporaron los *pi-ratings* a su dataset, siendo esta la feature que más impactó positivamente en sus predicciones tras hacer un análisis de importancia de variables. Razali et al. (2022) también uso *pi-ratings* para entrenar un modelo TabNet con la misma bases de datos del challenge y superando la propuesta ganadora tanto en accuracy como en RPS.

Berrar (2019) propusieron otra alternativa de rating systems. Este sistema, a diferencia de los anteriores, se basa en cuatro puntuaciones por equipo: fuerza ofensiva y debilidad defensiva, tanto en casa como fuera de casa. Además para la predicción del resultado del partido utilizan una función que combina los ratings de ambos equipos: fuerza ofensiva y debilidad defensiva del rival, además de algunas constantes que definen la forma de la función sigmoid que normaliza la predicción.

1.1.5 Specific-Domain Knowledge features

Además de estos grupos de features que hemos visto hasta ahora, muchos trabajos han propuesto features basadas en el conocimiento propio del fútbol.

Tax and Joubert (2015) añadió tres features relacionadas: los partidos del entrenador en el club, dos booleanos de si el máximo goleador y asistente están lesionados y la media de goles y asistencias del máximo goleador y asistente respectivamente. En relación con información individualizada de jugadores, Rodrigues and Pinto (2022) añadió estadísticas y características de jugadores puntuadas como enteros del 0 al 100 basadas en el videojuego FIFA de ES Sports³.

En cambio, si un trabajo propuso o incorporó features de este tipo, estos fueron Hubáček (2019). Una de las features que incorporó fue el algoritmo de *PageRank* aplicado a rankear equipos de fútbol propuesto por Lazova and Basnarkov (2015). Esta feature se añadió, asumiendo que los mejores equipos ganan a los mejores, para compensar la deficiencia de las features históricas de que no contienen información acerca del nivel de los rivales contra los que ha jugado un equipo. En la matriz calculada, en la cual se relacionan los equipos de cada competición entre ellos, se relaciona la dominancia de uno sobre otro en base a los enfrentamientos previos. Hubáček (2019) argumentan que *PageRank* además complementa *pi-ratings* ya que consiste en una variable más estática respecto a los *pi-ratings*. En la evaluación de las features concluyeron que *PageRank* había sido la segunda variable más influyente en las predicciones del modelo, solo tras *pi-ratings*.

Una feature que propusieron Hubáček (2019) totalmente nueva fue *Match Importance*. Esta variable pretendía representar la importancia de un partido en base a la situación de los dos equipos en la clasificación y del momento de la temporada. Como hemos mencionado anteriormente, representar directamente la posición en la tabla y los puntos es problemático ya que varía mucho en diferentes momentos de la temporada y en distintas competiciones. Por eso hicieron diez variables, comparando los

³Public data in www.sofifa.com

puntos de un equipo y la distancia relativa respecto a los puntos de los cinco primeros y cinco últimos de la clasificación.

1.2 Feature selection

La selección de características o reducción de dimensionalidad es un paso crucial porque ayuda a eliminar datos irrelevantes o redundantes, reduciendo el ruido y mejorando la eficiencia de los algoritmos de aprendizaje. Esto no solo acelera el entrenamiento al disminuir la carga computacional, sino que también mejora el rendimiento del modelo al enfocarse en las variables más relevantes, evitando el overfitting y facilitando la interpretabilidad de los resultados.

[Tax and Joutstra \(2015\)](#) evaluaron diferentes algoritmos conocidos de reducción de dimensionalidad: PCA, Sequential Forward Selection y ReliefF, y una nueva propuesta suya, Correlation-based Feature Subset Selection. Finalmente, tras realizar los experimentos, obtuvieron los mejores resultados con PCA, siendo los siguiente mejores resultados con la totalidad de las variables del dataset. [Yu et al. \(2022\)](#), aplicaron Logistic Lasso, para analizar estadísticamente la proporcionalidad de las variables con el resultado del partido. [Rodrigues and Pinto \(2022\)](#) crearon, durante la exploración de los datos una matriz de correlaciones de variables para ver que features estaban más mutuamente relacionadas y poder eliminar features redundantes. También compararon la correlación de las variables con el resultado final. Después para seleccionar las mejores features creadas, utilizaron un algoritmo heurístico de selección de variables basado en Random forests, *Boruta* algorithm, propuesto por primera vez en [Kursa and Rudnicki \(2010\)](#).

1.3 Model proposal

En cuanto a los modelos de predicción que se han utilizado para entrenar las features creadas en los distintos trabajos, tenemos también diferentes enfoques y algoritmos.

[Rodrigues and Pinto \(2022\)](#) compararon diferentes algoritmos a partir del acierto y el profit obtenido en el test set. El resultado de la comparación fue que los algoritmos basados en árboles (Random Forest y Gradient-Boosting Trees) eran los más aptos para este problema, aunque la diferencia con algoritmos como Support Vector Machines no era significativas. [Vashist et al. \(2022\)](#) usaron un Voting Classifier incorporando los algoritmos que mejor resultados les había dado individualmente en unos experimentos iniciales. Incorporaron al Voting Classifier: XGBoost, Logistic Regression y Gradient-Boosting. Los algoritmos basados en Gradient-boosting Trees han sido ampliamente usados para este problema de clasificación [[Hubáček \(2019\)](#); [Berrar \(2019\)](#)] por los buenos resultados que proporcionan con datos tabulares.

ANN también han sido ampliamente utilizados como algoritmos de aprendizaje, especialmente con redes poco profundas [[Muszaidi et al. \(2022\)](#); [Jain et al. \(2021\)](#); [S.K. et al. \(2022\)](#)]. [Li \(2020\)](#) usó una adaptación mejorada de un Multi-layer Perceptron. La adaptación busca una convergencia más rápida del modelo, evitando el problema de los mínimos locales. La adaptación consiste en añadir una variable dinámica que adapta el grado del update según el error del modelo. Cuando el error disminuye consistentemente, el tamaño del paso puede aumentar para acelerar la convergencia.

Por el contrario, si el error aumenta o fluctúa, el tamaño del paso se reduce para estabilizar el proceso de optimización y evitar caer en mínimos locales.

Finalmente, [Razali et al. \(2022\)](#) utiliza, por primera vez en este problema de clasificación el algoritmo TabNet, propuesto por [Arik and Pfister \(2019\)](#). TabNet es un algoritmo de ANN diseñado específicamente para entrenar datos tabulares. Utiliza un mecanismo de atención secuencial que selecciona de manera dinámica las características más relevantes para cada instancia, mejorando la eficiencia del aprendizaje y permitiendo una interpretación clara de la importancia de las características. Destaca también su capacidad de entrenarse de manera supervisada y no supervisada, junto con su capacidad para explicar sus decisiones a nivel local y global.

1.4 Conclusions

Como hemos mencionado anteriormente, todos estos trabajos han tenido que usar toda su creatividad para crear características que aportaran más información al algoritmo de aprendizaje automático, ya que los datasets públicos disponibles en la red son muy limitados ya sea en riqueza y detalle de información de los partidos, o en volumen de partidos.

Han sido muy pocos los trabajos que han decidido usar datasets con una granularidad fina de detalle, ya que la mayoría ha preferido tener un volumen importante de datos. Características como Pank Range, Match Importance o los sistemas de rating son ejemplos de que se pueden crear características complejas que combinan muchos factores que influyen en el resultado de los partidos, seguramente los factores más influyentes, los goles.

Un problema que se encuentran muchos investigadores al leer acerca de la literatura de este problema es que muchos trabajos utilizan métricas diferentes para evaluar sus trabajos. La mayoría utilizan el accuracy general, y muchos otros algún tipo de métrica error, como por ejemplo RPS, que era la métrica tomada como criterio de ganador del *2017 Soccer Prediction Challenge*.

A la hora de analizar los resultados, el principal problema que se han encontrado los investigadores han sido los empates, los cuales son extremadamente difíciles de pronosticar según las investigaciones recientes. Sin embargo, aún así, hemos notado que no ha habido ningún estudio enfocado realmente a mejorar la predicción en dichos resultados que suponen cerca del 27% del total de partidos.

Declarations

Some journals require declarations to be submitted in a standardised format. Please check the Instructions for Authors of the journal to which you are submitting to see if you need to complete this section. If yes, your manuscript must contain the following sections under the heading ‘Declarations’:

- Funding
- Conflict of interest/Competing interests (check journal-specific guidelines for which heading to use)
- Ethics approval and consent to participate

- Consent for publication
- Data availability
- Materials availability
- Code availability
- Author contribution

If any of the sections are not relevant to your manuscript, please include the heading and write ‘Not applicable’ for that section.

Editorial Policies for:

Springer journals and proceedings: <https://www.springer.com/gp/editorial-policies>

Nature Portfolio journals: <https://www.nature.com/nature-research/editorial-policies>

Scientific Reports: <https://www.nature.com/srep/journal-policies/editorial-policies>

BMC journals: <https://www.biomedcentral.com/getpublished/editorial-policies>

References

- Aranda-Corral, B.-D.J..G.-P.J. G.A.: Complex concept lattices for simulating human prediction in sport. *J Syst Sci Complex* **26**, 117–136 (2013) <https://doi.org/10.1007/s11424-013-2288-x>
- Arik, S.Ö., Pfister, T.: Tabnet: Attentive interpretable tabular learning. *CoRR abs/1908.07442* (2019) [1908.07442](https://arxiv.org/abs/1908.07442)
- Berrar, L.P..D.W. D.: Incorporating domain knowledge in machine learning for soccer outcome prediction. *Mach Learn* **108**, 97–126 (2019) <https://doi.org/10.1007/s10994-018-5747-8>
- Berrar, D., LOPES, P., Davis, J., Dubitzky, W.: The 2017 Soccer Prediction Challenge. OSF (2017). <https://doi.org/10.17605/OSF.IO/FTUVA> . osf.io/ftuva
- Constantinou, A., Fenton, N.: Determining the level of ability of football teams by dynamic ratings based on the relative discrepancies in scores between adversaries. *Journal of Quantitative Analysis in Sports* **9**, 37–50 (2013) <https://doi.org/10.1515/jqas-2012-0036>
- Elo, A.E.: The Rating of Chessplayers, Past and Present. Arco Pub., ??? (1978). <https://books.google.es/books?id=8pMnAQAAMAAJ>
- Hvattum, L.M., Arntzen, H.: Using elo ratings for match result prediction in association football. *International Journal of Forecasting* **26**(3), 460–470 (2010) <https://doi.org/10.1016/j.ijforecast.2009.10.002> . Sports Forecasting

- Heuer, A., Rubner, O.: Fitness, chance, and myths: An objective view on soccer results. *European Physical Journal B* **67**, 445–458 (2009) <https://doi.org/10.1140/epjb/e2009-00024-8>
- Hucaljuk, J., Rakipović, A.: Predicting football scores using machine learning techniques. In: 2011 Proceedings of the 34th International Convention MIPRO, pp. 1623–1627 (2011)
- Hubáček, G., O.: Learning to predict soccer results from relational data with gradient boosted trees. *Mach Learn* **108**, 29–47 (2019) <https://doi.org/10.1007/s10994-018-5704-6>
- Ievoli, R., Palazzo, L., Ragozini, G.: On the use of passing network indicators to predict football outcomes. *Knowledge-Based Systems* **222**, 106997 (2021) <https://doi.org/10.1016/j.knosys.2021.106997>
- Jain, S., Tiwari, E., Sardar, P.: Soccer Result Prediction Using Deep Learning and Neural Networks, pp. 697–707 (2021). https://doi.org/10.1007/978-981-15-9509-7_57
- Kursa, M.B., Rudnicki, W.R.: Feature selection with the boruta package. *Journal of Statistical Software* **36**(11), 1–13 (2010) <https://doi.org/10.18637/jss.v036.i11>
- Lazova, V., Basnarkov, L.: Pagerank approach to ranking national football teams. *CoRR* **abs/1503.01331** (2015) [1503.01331](https://arxiv.org/abs/1503.01331)
- Li, H.: Analysis on the construction of sports match prediction model using neural network. *Soft Comput* **24**, 8343–8353 (2020)
- Muszaiddi, M., Mustapha, A., Ismail, S., Razali, N.: Deep Learning Approach for Football Match Classification of English Premier League (EPL) Based on Full-Time Results, pp. 339–350 (2022). https://doi.org/10.1007/978-981-16-8903-1_30
- Rudrapal, D., Boro, S., Srivastava, J., Singh, S.: A Deep Learning Approach to Predict Football Match Result, pp. 93–99 (2020). https://doi.org/10.1007/978-981-13-8676-3_9
- Rein, M.D. R.: Big data and tactical analysis in elite soccer: future challenges and opportunities for sports science. *SpringerPlus* **5**(1410) (2016)
- Razali, N., Mustapha, A., Arbaiy, N., Lin, P.-C.: Deep learning for football outcomes prediction based on football rating system. *AIP Conference Proceedings* **2644**(1), 040007 (2022) <https://doi.org/10.1063/5.0104587> <https://pubs.aip.org/aip/acp/article-pdf/doi/10.1063/5.0104587/16228035/040007.1.online.pdf>
- Rodrigues, F., Pinto, : Prediction of football match results with machine learning.

- Procedia Computer Science **204**, 463–470 (2022) <https://doi.org/10.1016/j.procs.2022.08.057>
- S.K., N., Geetha, M., R C, S., Prabakaran, R., Madhuvanan, S., Sameer, A.: A deep learning framework for football match prediction, pp. 1–7 (2022). <https://doi.org/10.1109/ICCCI54379.2022.9740760>
- Timmaraju, A.S.: Game on! predicting english premier league match outcomes. (2013). <https://api.semanticscholar.org/CorpusID:15852249>
- Tax, N., Joulstra, Y.: Predicting The Dutch Football Competition Using Public Data: A Machine Learning Approach. <https://doi.org/10.13140/RG.2.1.1383.4729>
- Ulmer, B., Fernández, M.P.: Predicting soccer match results in the english premier league. (2014). <https://api.semanticscholar.org/CorpusID:9148671>
- Vashist, M., Bahl, V., Sengar, N., Goel, A.: Machine learning for football matches and tournaments. In: 2022 International Conference on Machine Learning, Big Data, Cloud and Parallel Computing (COM-IT-CON), vol. 1, pp. 489–496 (2022). <https://doi.org/10.1109/COM-IT-CON54601.2022.9850673>
- Wang, Q., Zhu, H., Hu, W., Shen, Z., Yao, Y.: Discerning tactical patterns for professional soccer teams: An enhanced topic model with applications. (2015). <https://doi.org/10.1145/2783258.2788577>
- Yu, G., Yang, J., Chen, X., Qian, Z., Sun, B., Jin, Q.: Prediction of Game Result in Chinese Football Super League, pp. 613–624 (2022). https://doi.org/10.1007/978-981-19-9195-0_49