



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Un estudio sobre el desempeño de algoritmos de aprendizaje automático para la predicción de resultados de partidos profesionales de fútbol

Guillem Pruñonosa Soler

Víctor Sánchez Anguix

Juan Miguel Alberola Oltra

Universitat Politècnica de València

28 de marzo de 2023

- ① Introducción
- ② Estado del arte
- ③ Solución propuesta
- ④ Generación de los datasets
- ⑤ Experimentos
- ⑥ Conclusiones

- 1 Introducción
- 2 Estado del arte
- 3 Solución propuesta
- 4 Generación de los datasets
- 5 Experimentos
- 6 Conclusiones

Predicción de resultados de fútbol

Auge del análisis de datos en el futbol, y más en concreto de la predicción de los resultados.

Aplicaciones

- Mejora del rendimiento de un equipo o jugador.
- Toma de decisiones de los entrenadores.
- Ojeo de jugadores

Objetivos

- Crear un modelo predictivo capaz de predecir el resultado de un partido de fútbol.
- Encontrar los factores que más influyen en el resultado.

- 1 Introducción
- 2 Estado del arte**
- 3 Solución propuesta
- 4 Generación de los datasets
- 5 Experimentos
- 6 Conclusiones

Estado del Arte en la predicción de resultados de fútbol.

Nombre del trabajo	Tipo de Datos	Datos	Algoritmo	Red. dim	Clases	Acierto	Problemas
Predicting the dutch football competition using public data: A machine learning approach.	Odds Stats +	13 temp.	Naive Bayes, MLP	Si (PCA)	3	54.7 %	Predicción de empates
A deep learning framework for football match prediction.	Events Embeddings	WC 2018	LSTM	No	3	63.3 %	No tiene en cuenta los partidos pasados.
Soccer result prediction using deep learning and neural networks.	Stats	8 temp. EPL	LSTM	No	2	80 %	Solo usan datos de los últimos 3 y 5 partidos.
A deep learning approach to predict football match result	Stats	16 temp. EPL	MLP	Si	2	73.6 %	Solo usan datos de los últimos 5 partidos.
Predicting soccer match results in the english premier league.	Stats	12 temp. EPL	Naive Bayes, SVM, MLP (best)	Si	3	52 %	Predicción de empates.
Football match prediction using deep learning	Events Embeddings	63 leagues	LSTM	Si	3	44 %	Predicción de empates.

Cuadro 1: Trabajos relacionados destacados

Crítica al Estado del arte

- Falta de datasets estandarizados.
- Falta de metodología estandarizada.
- Área de estudio muy cerrada.
- Dificultad de comparación de resultados.
- No se centran las predicciones en los partidos más problemáticos → empates
- No se utilizan datos de períodos largos de tiempo.

- 1 Introducción
- 2 Estado del arte
- 3 Solución propuesta**
Metodologia
- 4 Generación de los datasets
- 5 Experimentos
- 6 Conclusiones

La propuesta que hacemos es la siguiente:

- **Baselines:** con los que validar el aprendizaje de nuestros modelos predictivos más complejos.
- **Benchmark:** utilizamos las predicciones de las casas de apuestas para comparar nuestros resultados.
- **Dataset:**
 - ① Basado en eventos de los últimos 4 partidos
 - ② Basado en estadísticas de diferentes periodos de tiempo.
- **Algoritmos:**
 - ① Redes neuronales
 - ② LightGBM




Figura 1: Metodología empleada durante el trabajo.




Figura 2: Metodología empleada durante los experimentos.

- 1 Introducción
- 2 Estado del arte
- 3 Solución propuesta
- 4 Generación de los datasets**
- 5 Experimentos
- 6 Conclusiones

Base de datos de eventos

- Basado en eventos.
- Organizado en diversos ficheros CSV y JSON.
- Datos de 5 ligas.
- 1 temporada por liga.

type	subtype	tags
pass	cross, simple pass	accurate, not accurate, key pass, opportunity, assist, goal
shot		accurate, not accurate, block, opportunity, assist, goal
duel	air duel, dribbles, tackles, ground loose ball	accurate, not accurate
free kick	corner, shot, goal kick, throw in, penalty, simple kick	accurate, not accurate, key pass, opportunity, assist, goal
offside touch	acceleration, clearance, simple touch	counter attack, dangerous ball lost, missed ball, interception, opportunity, assist, goal
foul		no card, yellow, red, 2nd yellow

Base de datos de estadísticas

- Base de datos de libre acceso.
- Gran cantidad de ligas.
- Principales estadísticas de un partido.
- Desde la temporada 1993-1994 hasta 2021-2022.
- Formato tabular (CSV) y un fichero por liga y temporada.
- No contienen las mismas características.




Figura 3: Diferencia disparos ganador vs perdedor.

Draw	Home win	Away win
24.8 %	45.7 %	29.5 %

Cuadro 2: Distribución de los resultados de los partidos.




Figura 4: Serie temporal goles Atalanta.

Dataset basado en eventos:

- Variables basadas en los últimos 4 partidos del 11 titular del partido.

1826 registros	minutos	disparos	acierto disparo	goles	ratio goles
	pases	acierto pases	pases clave	ind. ataque	ind. defensa

Cuadro 3: Atributos del dataset generado basado en eventos.

Dataset basado en estadísticas:

- Short: diferentes *lags* de los últimos n partidos.
- Longterm: diferentes lags de corto y largo plazo.

Feature	Basic Short	Basic w/ Derby	Complete Short	Basic Longterm	Basic Longt. w/ Derby	Comp. Longterm
Side (home/away)	X	X	X	X	X	X
Scored goals	X	X	X	X	X	X
Received goals	X	X	X	X	X	X
Points	X	X	X	X	X	X
Shots			X			X
Shots on target			X			X
Corners			X			X
Fouls			X			X
Yellow Cards			X			X
Red Cards			X			X
Derby features		X			X	
# features (columns)	80	104	200	56	80	140
# matches (rows)	32.997	23.267	21.635	17.373	13.536	11.895

Cuadro 4: Atributos de los datasets generados basados en estadísticas.

1 Introducción

2 Estado del arte

3 Solución propuesta

4 Generación de los datasets

5 Experimentos

Baselines y Benchmark

Experimentos explorativos con ANN

Calibración de predicciones

Dataset histórico

Calibración con la diferencia de goles

Resultados

- **Baseline I:** siempre gana el equipo local $\Rightarrow$ acc 45.6 %
- **Baseline II:** gana el mejor del último mes $\Rightarrow$ acc 42.1 %




Figura 5: Baseline II confusion matrix

- **Benchmark:** gana el equipo con la cuota más baja $\Rightarrow$ acc 54.45 %




Figura 6: Benchmark confusion matrix



Figura 7:
Multi-layer
Perceptron

Experimentos explorativos de la arquitectura de la ANN.

Diferentes arquitecturas han sido probadas utilizando la misma configuración por defecto.

layers params.	Train Error				Test Error				Train Accuracy				Test Accuracy			
	3	4	10	20	3	4	10	20	3	4	10	20	3	4	10	20
500	0.89	0.89	1.07	1.06	1.33	1.32	1.07	1.07	0.59	0.6	0.45	0.45	0.33	0.43	0.43	0.43
750	0.85	0.86	0.86	0.89	1.39	1.39	1.32	1.31	0.62	0.61	0.63	0.67	0.45	0.39	0.3	0.28
1000	0.85	0.87	0.9	0.91	1.37	1.36	1.3	1.31	0.61	0.6	0.64	0.69	0.44	0.31	0.24	0.25
1500	0.83	0.82	0.9	0.9	1.38	1.44	1.29	1.33	0.64	0.63	0.65	0.66	0.32	0.44	0.38	0.35
2000	0.8	0.8	0.89	0.85	1.4	1.44	1.3	1.40	0.65	0.65	0.61	0.59	0.48	0.43	0.43	0.40
3000	0.76	0.74	0.75	0.72	1.5	1.55	1.71	1.88	0.69	0.7	0.66	0.58	0.43	0.4	0.33	0.35
5000	0.67	0.68	0.75	0.7	1.57	1.64	1.82	1.07	0.73	0.72	0.67	0.46	0.48	0.37	0.31	0.42
10000	0.52	0.37	0.7	0.62	1.78	2.49	1.82	2.15	0.82	0.9	0.66	0.74	0.38	0.4	0.42	0.43

Cuadro 5: Resultados con diferentes arquitecturas.

Infrajuste y sobreajuste

Existen diferentes problemas que hemos encontrado durante los experimentos explorativos.

- Añadir flexibilidad (complejidad) al modelo $\Rightarrow$ infrajuste
- Aprendizaje más rápido $\Rightarrow$ infrajuste
- Regularizar el modelo $\Rightarrow$ sobreajuste
- Añadir más datos

- ❶ **Batch Normalization**: optimizar el entrenamiento
- ❷ **Weight decay regularization**: deficiencias en el aprendizaje del modelo.
- ❸ **Drop-out regularization**: mejores resultados en el test.
- ❹ **Reducción de dimensionalidad**: simplificar el entrenamiento.

Model	Architecture	Optimizer	Lr.	Train err	Train acc	Test. err	Test acc	F1 draws	F1 home	F1 away
Drop-out	73-53-21-3	SGD	0.1	0.947	0.546	1.194	0.512	0.061	0.622	0.487
Drop-out	53-21-3	SGD	0.001	0.989	0.518	1.171	0.510	0.077	0.630	0.444
Drop-out	68-4-7-3	SGD	0.1	0.947	0.546	1.195	0.508	0.031	0.622	0.483
Drop-out	34-11-56	Adam	0.00001	0.992	0.512	1.123	0.508	0	0.619	0.509
Drop-out	42-18-18	Adam	0.001	0.934	0.544	1.201	0.508	0.264	0.621	0.428

Cuadro 6: Las 5 configuraciones con mejor acierto en el test.

Calibración de predicciones

Aplicamos una penalización mayor al error cometido en la predicción de empates.

(%)	Draws	Home wins	Away wins
Ground truth	24	45	31
Top accuracy (51.2%)	1	72	27
Top acc. on draws (F1 0.264)	11	68	21
Loss weights: 1.2 - 0.8 - 1.0	25	52	23
Loss weights: 1.1 - 0.9 - 1.0	6	54	40
Loss weights: 1.2 - 0.7 - 1.1	24	34	42

Cuadro 7: Distribución de las predicciones.




Figura 8: Gradientes entre penalizaciones diferentes.

Dataset histórico basado en estadísticas

- Más registros
- Datos de diferentes periodos de tiempo: corto y largo plazo.

Method \ Dims.	Historical Complete				Hist. Longterm Basic				Hist. Longterm Complete			
	3	8	15	23	5	15	25	55	10	25	50	140
All features	-	-	-	0.495	-	-	-	0.521	-	-	-	0.545
ANOVA	0.488	0.486	0.492	-	0.502	0.511	0.516	-	0.512	0.526	0.526	-
PCA	0.491	0.49	0.495	-	0.501	0.503	0.512	-	0.512	0.514	0.515	-

Cuadro 8: Resultados de experimento con dataset histórico (estadísticas).

Match	Res.	15 _H	15 _A	60 _H	60 _A	1825 _H	1825 _A	Historical Complete				Historical Longterm Complete			
								Proposal	D	H	A	Proposal	D	H	A
Everton - Man Utd	1-2	0	0.5	1.86	1.16	1.39	1.79	H	0.21	0.62	0.17	A	0.33	0.24	0.43
Elche - Real Madrid	0-0	3	1.5	1.86	2.25	1.03	2.43	A	0.26	0.36	0.37	A	0.34	0.23	0.43
Bremen - Hertha	2-0	3	1.5	2.5	1.12	1.17	1.32	H	0.14	0.77	0.09	H	0.34	0.42	0.23
Valladolid - Barça	0-2	2	2.3	1.37	1.55	1.08	2.28	H	0.27	0.38	0.35	A	0.34	0.21	0.45

Cuadro 9: Ejemplo de la influencia de los datos históricos.

$$t'_c = \minmax_c(d \cdot t_c) \cdot f \quad (1)$$

Factor \ Test metrics	Hist.Longterm Basic			Hist. Longterm Complete		
	error	accuracy	f1-score _{draws}	error	accuracy	f1-score _{draws}
no factor f (original)	0.98	0.521	0.2	0.98	0.545	0.15
label · goal diff. (no f)	1.9	0.52	0.02	1.88	0.523	0.02
$f = 2$	0.17	0.519	0.3	0.14	0.514	0.29
$f = 5$	0.34	0.516	0.31	0.27	0.516	0.29
$f = 10$	0.67	0.519	0.3	0.55	0.52	0.31

Cuadro 10: Resultados obtenidos con diferentes valores de f .

Goal difference	NO Factor	Only goal difference	$f = 1$	$f = 5$	$f = 10$
0	0.13	0	0.29	0.28	0.29
1	0.57	0.64	0.49	0.49	0.49
2	0.68	0.7	0.58	0.59	0.59
3	0.77	0.81	0.72	0.72	0.72
4	0.86	0.84	0.75	0.74	0.73
5	0.95	0.98	0.98	0.96	0.98
6	1	1	1	1	1
7	1	1	1	1	1
8	1	1	1	1	1

Cuadro 11: Acierto en función de la diferencia de goles que ha habido en el resultado.

Experimentos con LightGBM

- Optimización de hiperparámetros: Búsqueda baseyana con Optuna.

Model \ Test metrics	Hist. Longterm Basic		Hist. Longterm Complete	
	error	accuracy	error	accuracy
Basic LightGBM	0.99	0.527	0.99	0.525
ANOVA 25 dims	0.997	0.524	0.989	0.525
ANOVA 50 dims	0.992	0.532	0.987	0.529
PCA 25 dims	1.02	0.506	1.0	0.513
PCA 50 dims	1.01	0.512	0.995	0.519

Cuadro 12: Resultados experimentos con LightGBM.

- 1 Introducción
- 2 Estado del arte
- 3 Solución propuesta
- 4 Generación de los datasets
- 5 Experimentos
- 6 Conclusiones**
 - Comparación frente al benchmark
 - Resumen de las conclusiones

Resumen de resultados

Model \ League	Overall	ENG	SPA	GER	ITA	FRA
Benchmark (odds)	0.545	0.54	0.54	0.52	0.55	0.5
ANN (event based)	0.51	0.53	0.5	0.52	0.47	0.46
ANN (hist short term)	0.52	0.55	0.54	0.51	0.5	0.48
ANN (uncalibrated)	0.545	0.59	0.52	0.54	0.54	0.55
ANN (calibrated)	0.521	0.54	0.53	0.49	0.53	0.52
LightGBM	0.532	0.57	0.53	0.57	0.53	0.47

Cuadro 13: Acierto en el test (en general y por competición) durante los diferentes experimentos realizados y comparados con el Benchmark.

Benchmark vs nuestras predicciones

- Benchmark hace predicciones más fuertes (68 % veces).
- Mejores predicciones en partidos disputados ($\sim 35\%$).




Figura 9: Comparación de las cuotas y nuestras predicciones.

Conclusiones

- Resultados muy satisfactorios dadas las limitaciones en los datos → hemos igualado el acierto del Benchmark
- Hemos aplicado un enfoque nuevo para mejorar el acierto en los empates.
- Hemos mejorado el acierto en los empates del Estado del arte.
- Utilización de información a corto y largo plazo de un equipo para predecir el resultado.

Muchas gracias por vuestra atención!